

MODÈLE A

Hybrid Transition Intelligence

JADCO / Collection Équinoxe - PolyAI / CodeML 2026

Document de conception méthodologique et plan de construction

Ce document définit la méthodologie A avant son implémentation. Le modèle est construit au-dessus de la fondation commune anti-leakage déjà validée. Il ne modifie ni la cohorte, ni les cutoffs, ni la target, ni le protocole de backtest afin de préserver une comparaison équitable avec le futur Modèle B.

Élément	Décision Modèle A
Architecture	Deux étages : occurrence de transition + croissance conditionnelle
Occurrence p_i	Régression logistique régularisée, challengée par baseline historique
Croissance g_i	HistGradientBoostingRegressor, challengé par Ridge/ElasticNet
Agrégation	P1 : médiane des contributions attendues $p_i \times g_i$
Validation	Walk-forward strict 2023 / 2024 / 2025
Priorité	Erreur absolue sur l'indice agrégé, puis stabilité et métriques secondaires
Sortie 2026	Prévision + incertitude + facteurs explicatifs + limites

1. Position du Modèle A dans le système

Le Modèle A ne redéfinit pas le problème. La fondation commune a déjà déterminé ce qui peut être prédit sans fuite temporelle. A intervient uniquement pour améliorer l'estimation de deux quantités : la probabilité qu'une unité à échéance réalise une transition et la croissance de loyer attendue si cette transition se produit.

Principe : Cohorte connue au cutoff → features admissibles → $p_i \rightarrow g_i \rightarrow p_i \times g_i \rightarrow$ agrégation robuste → prévision → explicabilité et incertitude.

Ce qui est figé et ne doit pas être optimisé pour favoriser A

- Population : unités dont l'échéance contractuelle est connue au cutoff.
- Cutoffs : 2022-12-31 pour 2023, 2023-12-31 pour 2024, 2024-12-31 pour 2025, 2025-12-31 pour 2026.
- Target de croissance : croissance annualisée du loyer effectif entre transitions same-unit.
- Architecture business : P1, et non un rent roll complet.
- Backtests : 2023, 2024 et 2025, sans information future.
- Interdictions : nouveau loyer, nouvelle concession, nouveau bail, sRenewal futur, occurrence future et toute information post-cutoff.

2. Fondement empirique

L'analyse préalable a montré qu'une simple croissance globale du portefeuille est trompeuse. En 2023, la croissance contractuelle globale était d'environ 10,850 %, contre environ 2,344 % en same-unit. Le modèle doit donc raisonner sur des transitions comparables plutôt que sur une moyenne brute de loyers.

Observation	Résultat	Conséquence
Transitions same-unit	3 241 / 892 unités	Base principale du modèle de croissance
2025 contractual vs effective	7,177 % vs 3,714 %	Loyer effectif retenu comme mesure économique principale
Transition 2023	99,012 %	Occurrence presque certaine, mais non exactement 100 %
Transition 2024	98,295 %	Même constat
Transition 2025	90,304 %	Dérive importante à modéliser ou quantifier
Non-transitions 2025	83, dont 65 Saint-Elzéar	Signal descriptif, jamais traité comme causalité

3. Définition mathématique

3.1 Croissance conditionnelle

Pour une transition same-unit admissible, la croissance annualisée du loyer effectif est définie par :

$$G_i = (R_{\text{effectif,nouveau}} / R_{\text{effectif,ancien}})^{(365,25 / \Delta \text{jours})} - 1$$

L'annualisation utilise l'intervalle réel entre les débuts des baux et non sTermMonths. Elle a été validée sur le domaine observé : les médianes brute et annualisée diffèrent très peu en 2023, 2024 et 2025. Les intervalles courts peuvent amplifier les extrêmes, mais ils ne sont pas supprimés arbitrairement.

3.2 Occurrence de transition

$$p_i = P(T_i = 1 \mid X_i \text{ connu au cutoff})$$

La cohorte est déterminée avant l'année cible. Le label d'occurrence est révélé seulement pour l'évaluation. Le modèle ne peut jamais utiliser la transition future réelle pour sélectionner les lignes.

3.3 Indice P1

$$\text{Forecast}_A(Y) = 100 \times \text{médiane}_i [p_{\text{hat}_i} \times g_{\text{hat}_i}]$$

Cette quantité est un indice médian de contribution attendue des transitions à la croissance annualisée du loyer effectif des unités à échéance. Elle ne doit pas être présentée comme la croissance complète du rent roll. Mathématiquement, cette médiane de contributions prédites n'est pas l'espérance de la médiane réalisée ; cette distinction doit rester explicite.

4. Cohorte 2026

Au cutoff du 31 décembre 2025, 931 unités sont candidates pour 2026. Cette cohorte est construite sans information postérieure au cutoff.

Segment	Unités
Québec	810
Ontario	121
Daniel-Johnson	128
Le Carlyle	180
Lévesque	75
Saint-Elzéar	268
The Met	121
Westpark	159

5. Architecture du Modèle A

5.1 Sous-modèle A1 - Occurrence de transition

Le modèle principal proposé est une régression logistique régularisée. Le faible nombre de non-transitions, surtout avant 2025, rend une méthode fortement flexible risquée. La régression logistique fournit des probabilités, se régularise facilement et reste interprétable.

- Champion candidat : Logistic Regression régularisée.
- Baseline obligatoire : taux historique global de transition disponible au cutoff.
- Règle : le ML n'est retenu que s'il améliore réellement Brier/calibration et ne détériore pas la stabilité portefeuille.
- 2025 : traiter la chute à 90,304 % comme possible dérive de régime, pas comme règle Saint-Elzéar.
- Classes déséquilibrées : ne jamais juger le modèle sur l'accuracy seule.

5.2 Sous-modèle A2 - Croissance conditionnelle

Le champion candidat est HistGradientBoostingRegressor de scikit-learn. Il permet de capturer des non-linéarités et interactions entre caractéristiques d'unité, position de loyer, historique et contexte, sans ajouter une dépendance externe lourde.

Il est challengé par un modèle linéaire régularisé Ridge/ElasticNet. Cette comparaison permet de vérifier si la complexité non linéaire apporte une vraie valeur hors échantillon.

5.3 Pourquoi un système hybride

L'occurrence et la croissance n'ont ni le même label, ni le même déséquilibre, ni la même structure statistique. Les séparer permet d'utiliser une méthode conservatrice et calibrée pour p_i et une méthode plus expressive pour g_i . L'agrégateur P1 reconnecte ensuite les deux sous-problèmes.

6. Feature engineering

Le Modèle A doit privilégier des variables ayant une interprétation économique claire et disponibles au cutoff. Toute feature dérivée doit être recalculée à l'intérieur de chaque backtest afin d'éviter qu'une statistique future ne fuite dans le passé.

Famille	Exemples	Rôle
Historique unité	ancien loyer effectif/contractuel, croissance précédente, historique médian	Mémoire propre de l'unité
Position de loyer	loyer actuel / médiane segment comparable au cutoff	Mesurer sous/sur-positionnement
Concessions	gap contractuel-effectif de l'ancien bail	Mesurer intensité d'incitation connue
Bâtiment/segment	property, province, bedrooms, sqft, caractéristiques stables admissibles	Hétérogénéité structurelle
Temps	mois d'échéance, saison, récence	Saisonnalité et dérive
Dynamique récente	médiane récente bâtiment/portefeuille calculée avant cutoff	Contexte locatif récent
Externe	seulement availability_verified=True et disponible avant cutoff	Contexte additionnel, jamais dépendance

7. Features strictement interdites

La qualité du Modèle A dépend autant de ce qu'il refuse d'utiliser que de ses algorithmes. Les informations suivantes sont interdites lorsqu'elles appartiennent au futur de la prédiction :

- nouveau loyer contractuel ou effectif ;
- nouvelle concession ou reconstruction utilisant une concession future ;
- nouvelle date de bail inconnue au cutoff ;
- sRenewal du nouveau bail ;
- occurrence future réelle ;
- composition future réellement observée ;
- statistiques de segment calculées avec des observations post-cutoff ;
- données externes dont la date de disponibilité historique n'est pas vérifiée.

8. Gestion du temps et du concept drift

Le Modèle A testera une hypothèse de recency weighting. Les observations récentes peuvent être plus représentatives de 2026 que celles de 2017. Une pondération temporelle décroissante peut être testée, par exemple $w = \exp(-\lambda \times \text{âge})$, mais elle ne sera conservée que si les backtests montrent un gain robuste. λ ne doit pas être choisi sur 2026.

La chute du taux de transition en 2025 constitue le principal signal de dérive. Si les features disponibles avant 2025 ne permettent pas de l'anticiper, le modèle ne doit pas apprendre après coup une règle artificielle. La dérive devient alors une source d'incertitude explicitement rapportée.

9. Protocole de backtest

Chaque année est simulée comme si l'équipe se trouvait réellement au 31 décembre précédent. Toutes les transformations, agrégats de segments et variables historiques doivent être calculés à partir du passé admissible uniquement.

Année test	Prediction origin	Cohorte candidate	Transitions réalisées
2023	2022-12-31	405	401
2024	2023-12-31	645	634
2025	2024-12-31	856	773

10. Model Tournament interne

A n'est pas un algorithme choisi d'avance : c'est un protocole de sélection. Les candidats sont comparés sur les mêmes fenêtres temporelles. La priorité est l'utilité business au niveau agrégé.

Composante	Candidats	Critères principaux
Occurrence	Taux historique vs Logistic Regression	Brier, calibration, recall, stabilité
Growth	Ridge/ElasticNet vs HistGradientBoosting	MAE, RMSE, biais, stabilité annuelle
P1 complet	Combinaisons gagnantes $p_i + g_i$	Erreur absolue portefeuille 2023/24/25 en priorité

11. Baseline P1 à battre

La baseline d'occurrence actuelle utilise le taux historique global qualifié. Ces résultats constituent le niveau de référence commun ; A ne peut être qualifié d'amélioration que s'il apporte un gain hors échantillon sans dégrader fortement la stabilité.

Année	Indice prévu	Référence réalisée	Erreur
2023	2,843 %	2,036 %	+0,807 pp
2024	3,371 %	1,608 %	+1,763 pp
2025	3,118 %	3,301 %	-0,183 pp

12. Incertitude

Le forecast final ne doit pas être présenté comme un point parfaitement certain. Après sélection des sous-modèles, A construira une estimation d'incertitude reproductible, idéalement par bootstrap de la cohorte et/ou des résidus selon ce que les données permettent. Les sorties Low/Base/High doivent provenir d'une procédure statistique documentée et non d'un $\pm$ arbitraire.

13. Explicabilité et couche IA

L'explicabilité doit provenir du pipeline. Pour chaque forecast, le système génère un payload structuré contenant les prédictions, les facteurs réellement calculés, les métriques de backtest, les risques et l'incertitude. Une couche IA peut ensuite transformer ce payload en explication humaine, mais elle ne doit jamais inventer de driver absent des résultats.

Principe : No number without a reason. Chaque nombre important doit pouvoir être relié à une définition, des données, une méthode, des drivers et une mesure de fiabilité.

Exemple de payload conceptuel

```
{ "forecast_year": 2026, "predicted_growth": "...", "occurrence_model": "...", "growth_model": "...",  
  "features_used": [...], "backtest_by_year": { "...": "..."}, "drivers": [...], "risk_factors": [...],  
  "uncertainty": { "low": "...", "base": "...", "high": "..."} }
```

14. Phases de construction du Modèle A

A0 - Verrouillage du contrat

Vérifier le Foundation Freeze, les cutoffs, la liste fermée de features, la target P1 et les tests anti-leakage. Aucun modeling avant réussite.

A1 - Feature pipeline point-in-time

Implémenter les features historiques de l'unité, rent position, concession gap, dynamiques bâtiment/portefeuille, calendrier et encodages, recalculés séparément à chaque cutoff.

A2 - Occurrence baseline

Reproduire le taux historique global et établir Brier/calibration/recall par année. Ce résultat est le minimum à battre.

A3 - Occurrence ML

Entraîner Logistic Regression régularisée avec validation temporelle. Tester seulement quelques variantes justifiées. Conserver ML uniquement s'il apporte un gain robuste.

A4 - Growth baselines

Établir Ridge/ElasticNet et les baselines historiques sur G_i . Mesurer MAE, RMSE, biais et erreur agrégée.

A5 - Growth non linéaire

Entraîner HistGradientBoostingRegressor. Tester les interactions apprises contre le modèle linéaire sans tuning massif.

A6 - Recency experiment

Comparer poids égaux et pondération temporelle décroissante. Rejeter la récence si elle n'améliore pas les backtests.

A7 - Assemblage P1

Combiner p_hat_i et g_hat_i , calculer la médiane des contributions et exécuter les trois backtests complets.

A8 - Tournament

Sélectionner la combinaison A gagnante selon erreur portefeuille, stabilité, métriques secondaires et explicabilité.

A9 - Incertitude

Construire Low/Base/High par procédure statistique reproductible et documenter les limites.

A10 - Forecast 2026

Appliquer uniquement le pipeline gagnant aux 931 unités connues au 2025-12-31. Aucun retuning sur le résultat 2026.

A11 - Explainability

Générer drivers globaux/segmentaires, diagnostics et explanation_payload fondé sur les sorties réelles.

A12 - Packaging

Brancher estimate_2026(...), backtest(...), notebook final, figures, README, tests et éléments de présentation.

15. Discipline Software Engineering

Le modèle doit être un composant reproductible, testable et remplaçable. Les fonctions de feature engineering, entraînement, prédiction, agrégation et explication doivent être séparées. Les artefacts de modèle ne doivent jamais contenir de données CRM record-level destinées à être publiées.

- Configuration explicite des cutoffs et paramètres ; pas de magic numbers.
- Seeds déterministes lorsqu'ils existent.
- Tests unitaires du calcul de target, des splits et de l'anti-leakage.
- Tests de régression sur les cohortes 2023/2024/2025/2026.
- Interface commune compatible avec la comparaison Model B.
- Logs/résumés agrégés plutôt que dumps confidentiels.
- Documentation en français ; noms techniques/variables en anglais si plus clairs.
- Aucune dépendance à une source externe non historiquement qualifiée.

16. Critères de réussite du Modèle A

Critère	Condition de réussite
Validité	Aucune fuite temporelle ou de cohorte détectée
Occurrence	Probabilités raisonnablement calibrées ; ML utilisé seulement s'il bat la baseline
Growth	Amélioration hors échantillon ou stabilité supérieure à la baseline
Business	Erreur P1 agrégée compétitive sur 2023/24/25
Robustesse	Pas de victoire reposant sur une seule année
Explicabilité	Drivers reliés à des métriques/features réellement calculées
Reproductibilité	Pipeline relançable et compatible starter.ipynb

17. Ce que le Modèle A ne doit pas devenir

- Un concours de 15 algorithmes avec tuning massif et trois années de validation.
- Un modèle entraîné sur sRenewal futur ou toute information du nouveau bail.
- Un système qui force des données externes uniquement pour cocher une case.
- Un modèle qui transforme l'association Saint-Elzéar 2025 en causalité.
- Un forecast présenté comme rent roll complet alors que P1 est événementiel.
- Une IA générative qui invente des explications après coup.
- Une méthodologie modifiée après avoir vu quel choix donne le meilleur 2026.

18. Différenciation attendue avec le Modèle B

A représente l'hypothèse ML hybride au niveau unité : probabilité d'occurrence + régression conditionnelle, feature engineering économique et modèle non linéaire challengé par des modèles régularisés. B devrait tester une hypothèse suffisamment différente - par exemple hiérarchique, segmentaire, analogue ou statistique - tout en utilisant exactement le même contrat de données et d'évaluation. Un ensemble A+B ne sera retenu que s'il améliore objectivement le backtest.

19. Décision de conception

Model A - Hybrid Transition Intelligence est donc un système prédictif à deux étages, anti-leakage, history-aware et économiquement interprétable. Son ambition n'est pas d'être le modèle le plus complexe : elle est de faire en sorte que chaque couche de complexité réponde à un phénomène réel observé dans les données et démontre sa valeur sur les backtests.

La prochaine étape après validation humaine de ce document est A0/A1 : verrouiller le contrat dans le repo puis construire le feature pipeline point-in-time. Aucun forecast final 2026 ne doit être produit avant la sélection du pipeline gagnant sur 2023-2025.